

마스킹 이산 확산 언어 모델을 위한 측지 모멘텀 샘플링

추론 시점 Fisher-Rao 외삽법

Yoonseong Jeong

KAIST 전산학부

검토용 번역 초안 — 2026년 7월

초록

마스킹 이산 확산 언어 모델은 범주형 잡음 제거 전이를 연속적으로 수행하여 텍스트를 생성한다. 본 연구는 토큰별 범주형 예측을 Fisher-Rao 통계 다양체 위의 점으로 취급하는 추론 시점 수정법을 다룬다. 제곱근 사상은 범주형 단체를 조구의 양의 직교영역에 매장하며, 이 공간에서는 단형식의 구면 보간을 사용할 수 있다. 각 역방향 단계에서 이전 외삽 예측에서 현재 모델 예측을 통과하는 대원의 호를 재귀적으로 연장하고, 그 결과를 다시 범주형 분포로 변환한 뒤 원래 MDLM 또는 SEDD 전이에 삽입한다. 이 방법을 측지 모멘텀 샘플링이라 부른다.

정확한 기하학적 유도를 제시하고, 사영 이전 갱신이 지수사상에 의한 연장과 동치임을 증명하며, 작은 각도에서의 계수가 가변 스텝 2단계 Adams-Bashforth 외삽 계수와 일치함을 보인다. 동시에 이 유사성의 한계를 분명히 한다. 본 방법은 접벡터장이 아니라 예측 분포를 외삽하고, 확률적 범주형 점프를 유지하며, 양의 직교영역으로의 사영을 사용한다. 따라서 이 방법은 2차 정확도의 확률흐름 ODE 솔버가 아니며, 2차 수렴성을 주장하지 않는다. OpenWebText 체크포인트로 수행되어 보존된 실험 결과는 MDLM의 10-100 역방향 스텝과 SEDD의 10-50 스텝에서 GPT-2 생성 퍼플렉시티가 개선될 가능성을 보여준다.

1 서론

이산 확산 언어 모델은 병렬적이고 양방향적인 생성을 제공하지만, 정확한 샘플링에는 흔히 많은 역방향 전이가 필요하다. MDLM은 치환 매개화를 통해 흡수 상태 확산을 단순화하고 효율적인 캐시 샘플러를 제공한다 [Sahoo et al., 2024]. 반면 SEDD는 구체적인 스코어 비율을 학습하고 해석적인 역방향 전이를 허용한다 [Lou et al., 2024]. 두 모델은 모두 어휘집 위의 범주형 분포를 반복적으로 생성하는 방식으로 작동한다.

정보기하는 이러한 분포에 자연스러운 기하를 부여한다. 범주형 단체의 내부에는 Fisher-Rao 계량이 정의되며 [Amari, 2016], 제곱근 사상은 상수 배율을 제외하면 이를 구면의 양의 직교영역과 동일시한다. 이 구조는 Fisher-Flow [Davis et al., 2024]와 연속 리만 확산 언어 모델(RDLM) [Jo and Hwang, 2025]의 토대이기도 하다. 이들 방법은 구면 위의 연속 흐름을 학습하거나 시뮬레이션한다. 본 연구의 설정은 다르다. 사전학습된 이산 MDLM과 SEDD는 그대로 유지하고, 추론 시점의 범주형 예측만 수정한다.

본 연구의 주요 기여는 다음과 같다.

- 정확한 제곱근 매장과 구면 선형 보간(SLERP)을 사용해 범주형 예측을 재귀적으로 측지 외삽하는 방법을 정식화한다.
- 사영 이전 갱신이 지수사상에 의한 연장임을 보이고, 국소적인 Adams-Bashforth 유사 계수 구조를 유도한다.
- 동일한 기하 연산자를 MDLM의 정답 토큰 예측과 SEDD의 해석적 전이 분포라는 서로 다른 두 인터페이스에 적용한다.
- 불변량과 고차 방법과의 유사성이 성립하는 정확한 범위를 명시한다. 특히 본 알고리즘을 RDLM 확률흐름 ODE 솔버와 동일시하지 않는다.
- 여섯 가지 역방향 스텝 수에서 MDLM 및 SEDD의 품질 결과를 보고한다.

2 배경

2.1 범주형 Fisher–Rao 기하

범주형 확률 단체를 다음과 같이 두자.

$$\Delta^{V-1} = \left\{ p \in \mathbb{R}^V : p_k \geq 0, \sum_{k=1}^V p_k = 1 \right\}. \quad (1)$$

단체의 내부에서 접벡터는 $\sum_k v_k = 0$ 을 만족하며, Fisher–Rao 계량은

$$g_p(v, w) = \sum_{k=1}^V \frac{v_k w_k}{p_k} \quad (2)$$

이다.

명제 1 (제곱근 등거리사상). $\Psi : \text{int}(\Delta^{V-1}) \rightarrow \mathbb{S}_+^{V-1}(2)$ 를 원소별 연산 $\Psi(p) = 2\sqrt{p}$ 로 정의하자. 여기서 $\mathbb{S}_+^{V-1}(2)$ 는 반지름이 2인 구면의 양의 직교영역이다. 그러면 Ψ 는 Fisher–Rao 계량과 주변 유클리드 공간이 유도하는 계량 사이의 등거리사상이다.

증명. $\psi_k = 2\sqrt{p_k}$ 이면 $d\psi_k = dp_k / \sqrt{p_k}$ 이므로

$$\|d\psi\|_2^2 = \sum_k \frac{dp_k^2}{p_k} = ds_{\text{FR}}^2. \quad (3)$$

또한 $\|\psi\|_2^2 = 4 \sum_k p_k = 4$ 이므로 ψ 는 반지름 2인 구면 위에 놓인다. $\square$

구현에서는 단위구면 좌표

$$u(p) = \sqrt{p} \in \mathbb{S}_+^{V-1} \quad (4)$$

를 사용한다. 이는 상수 2배만큼만 차이가 난다. $p, q \in \text{int}(\Delta^{V-1})$ 에 대해 두 점 사이의 구면각은

$$\omega(p, q) = \arccos \langle u(p), u(q) \rangle = \arccos \left(\sum_k \sqrt{p_k q_k} \right) \quad (5)$$

이고, 반지름 2 관례에서의 Fisher–Rao 거리는 $d_{\text{FR}}(p, q) = 2\omega(p, q)$ 이다. 이 거리 공식은 닫힌 단체로 연속적으로 확장되어 그 거리 완비화를 정의하지만, 경계점 자체는 Fisher–Rao 리만 다양체의 매끄러운 점이 아니다.

2.2 마스킹 이산 확산과 MDLM

$\mathbf{m}$ 을 흡수 마스크 상태, $\sigma(t)$ 를 적분 잡음 스케줄이라 하자. 시각 t 까지 마스크로 이동했을 확률은

$$m(t) = 1 - \exp[-\sigma(t)] \quad (6)$$

이다. 역방향 스텝 $t > s$ 에서 MDLM은 정답 토큰 분포 $p_{\theta,t}(\cdot | x_t)$ 를 예측한다. 흡수 상태 매개화에서는 $p_{\theta,t}(\mathbf{m} | x_t) = 0$ 이고 $\sum_{k \neq \mathbf{m}} p_{\theta,t}(k | x_t) = 1$ 이다. $x_t = \mathbf{m}$ 일 때 기준 구현은 다음 비정규화 가중치에서 표본을 추출한다.

$$\hat{q}_{s|t}^{\text{MDLM}}(k | x_t = \mathbf{m}) = \begin{cases} [m(t) - m(s)]p_{\theta,t}(k | x_t), & k \neq \mathbf{m}, \\ m(s), & k = \mathbf{m}. \end{cases} \quad (7)$$

범주형 샘플링에서는 공통 정규화 상수가 중요하지 않다. $x_t \neq \mathbf{m}$ 이면 흡수형 역방향 샘플러는 이미 마스크가 해제된 토큰을 그대로 복사한다. 캐시 샘플러는 이산 상태가 바뀔 때까지 $p_{\theta,t}$ 를 재사용한다 [Sahoo et al., 2024].

2.3 SEDD의 해석적 전이

SEDD는 $p_t(y)/p_t(x)$ 를 근사하는 구체적 스코어 비율을 학습한다 [Lou et al., 2024]. $r_\theta(x_t, t)$ 를 학습된 스코어 벡터, $\mathcal{S}_{\Delta\sigma}$ 를 staggered-score 변환, $K_{\Delta\sigma}(x_t, \cdot)$ 를 이동된 순방향 커널이라 하자. 해석적 샘플러는

$$\hat{q}_{s|t}^{\text{SEDD}} = \mathcal{S}_{\Delta\sigma}(r_\theta(x_t, t)) \odot K_{\Delta\sigma}(x_t, \cdot), \quad \Delta\sigma = \sigma(t) - \sigma(s) \quad (8)$$

를 사용한 뒤 범주형 샘플링을 수행한다. 본 SEDD 변형은 스코어 벡터 자체가 아니라 식 (8)을 정규화한 분포에 기하 연산을 적용한다.

3 측지 모멘텀 샘플링

3.1 공통 분포 인터페이스

각 배치 원소와 시퀀스 위치에 대해 역방향 인덱스 i 에서의 범주형 분포 $z_i \in \Delta^{V-1}$ 를 다음과 같이 정의한다.

$$z_i = \begin{cases} p_{\theta, t_i}(\cdot | x_{t_i}), & \text{MDLM,} \\ \text{Normalize}(\hat{q}_{t_{i+1}|t_i}^{\text{SEDD}}), & \text{SEDD.} \end{cases} \quad (9)$$

원래 구면 좌표는 $u_i = \sqrt{z_i}$ 이다. $\hat{u}_{i-1}$ 를 직전 단계에서 외삽된 좌표라 하자. 이 재귀적 선택은 중요하다. 즉, 본 방법은 최근 두 원시 예측만 보존하는 것이 아니라 지속적인 모멘텀을 갖는다.

3.2 정확한 구면 연장

단위벡터 $a, b \in \mathbb{S}^{V-1}$ 와 두 벡터 사이의 각 $\omega = \arccos\langle a, b \rangle \in (0, \pi)$ 에 대해 SLERP는 [Shoemake, 1985]

$$\text{Slerp}(a, b; \tau) = \frac{\sin[(1-\tau)\omega]}{\sin \omega} a + \frac{\sin(\tau\omega)}{\sin \omega} b \quad (10)$$

이다. 보간에는 $\tau \in [0, 1]$ 을 사용하지만, 본 연구에서는 $\tau = 1 + \alpha_i$ 를 선택한다.

$$e_i = \frac{\sin(-\alpha_i\omega_i)}{\sin \omega_i} \hat{u}_{i-1} + \frac{\sin[(1+\alpha_i)\omega_i]}{\sin \omega_i} u_i, \quad \omega_i = \arccos\langle \hat{u}_{i-1}, u_i \rangle. \quad (11)$$

명제 2 (지수사상 표현). 서로 다르고 대척점도 아닌 $a, b \in \mathbb{S}^{V-1}$ 와 $\alpha \geq 0$ 에 대해

$$\text{Slerp}(a, b; 1 + \alpha) = \text{Exp}_b[-\alpha \text{Log}_b(a)] \quad (12)$$

가 성립한다. 따라서 식 (11)은 아래에서 설명할 양수화 연산을 적용하기 전에 a 에서 출발해 b 를 지나는 대원의 호를 추가 비율 α 만큼 정확히 연장한다.

증명. $\gamma(\tau) = \text{Slerp}(a, b; \tau)$ 는 $\tau \in [0, 1]$ 에서 a 와 b 를 연결하는 유일한 최단 대원 구간이다. $b = \gamma(1)$ 에서 $-\text{Log}_b(a)$ 는 노름이 ω 인 순방향 연장 접벡터다. 크기가 조절된 벡터 $-\alpha \text{Log}_b(a)$ 에 Exp_b 를 적용하면 호의 길이 $\alpha\omega$ 만큼 전진하므로, 이는 정확히 $\gamma(1 + \alpha)$ 와 같다. $\square$

$a = b$, 즉 $\omega = 0$ 일 때는 연속 확장으로 $\text{Slerp}(a, a; \tau) = a$ 라 정의하며, 이 경우에도 명제는 성립한다. 식 (10) and (12)은 클램프하지 않은 이상적 연산자를 기술한다. 구현은 수치 안정성을 위해 각도를 다음과 같이 계산한다.

$$\arccos(\text{clamp}(\langle a, b \rangle, -1 + \varepsilon, 1 - \varepsilon)).$$

따라서 정확한 지수사상 항등식은 이상적 연산자에 대한 것이며, 실제 구현은 끝점 부근에서 안정화한 근사다.

3.3 양의 직교영역 사영과 확률 복원

대원을 따른 외삽은 양의 직교영역을 벗어날 수 있다. 보존된 구현은

$$\text{Proj}_+(e) = \frac{[e]_+}{\|[e]_+\|_2}, \quad [e]_{+,k} = \max(e_k, 0) \quad (13)$$

를 사용하고, 다음과 같이 확률을 복원한다.

$$\hat{z}_{i,k} = (\hat{u}_{i,k})^2, \quad \hat{u}_i = \text{Proj}_+(e_i). \quad (14)$$

명제 3 (확률의 유효성). $\|[e_i]_+\|_2 > 0$ 이면 복원된 벡터 $\hat{z}_i$ 는 Δ^{V-1} 에 속한다.

증명. 각 성분은 제곱이므로 음수가 아니다. 또한 $\hat{u}_i$ 의 노름이 1 이므로 $\sum_k \hat{z}_{i,k} = \sum_k \hat{u}_{i,k}^2 = 1$ 이다. $\square$

이 사영은 실용적인 영역 보정이며, 정확한 Fisher-Rao 측지선의 일부가 아니다. 성분이 0 을 가로지르는 곳에서 매끄럽지 않고 $[e]_+ = 0$ 이면 정의되지 않으므로, 고차 측지 적분기의 보장을 직접 계승할 수 없다.

3.4 스텝 계수와 AB2 유사성

감소하는 역방향 격자를 $t_0 > t_1 > \dots > t_N$ 이라 하고, 양의 스텝 크기를 $h_i = t_i - t_{i+1}$ 로 정의하자. 구현에서는

$$\alpha_i = c_i \frac{h_i}{2h_{i-1}}, \quad \alpha_0 = 0 \quad (15)$$

을 사용한다. 보존된 SEDD 실행에서는 $c_i = 1$ 이고, MDLM에서는

$$c_i = c \min\left(1, \frac{h_i}{h_{\text{ref}}}\right), \quad c = 1, \quad h_{\text{ref}} = \frac{1}{50} \quad (16)$$

을 사용한다.

명제 4 (국소 선형 형태). 고정된 α 와 $\omega = \arccos(a, b) \rightarrow 0$ 에 대해

$$\text{Slerp}(a, b; 1 + \alpha) = (1 + \alpha)b - \alpha a + O(\omega^2) \quad (17)$$

가 성립한다. $c_i = 1$ 이고 $r_i = h_i/h_{i-1}$ 이면 선도 계수는 $(1 + r_i/2, -r_i/2)$ 이며, 이는 가변 스텝 AB2의 계수와 일치한다.

증명. 식 (10)에서 $\tau = 1 + \alpha$ 로 두고 $\sin(\beta\omega)/\sin\omega = \beta + O(\omega^2)$ 를 사용하면 $\sin(-\alpha\omega)/\sin\omega = -\alpha + O(\omega^2)$ 및 $\sin[(1 + \alpha)\omega]/\sin\omega = 1 + \alpha + O(\omega^2)$ 를 얻는다. $\square$

비고 1 (리만 AB2가 아닌 이유). 리만 AB2는 V_{i-1} 을 $T_{X_i}\mathcal{M}$ 으로 평행이동한 뒤 접공간의 벡터장 $V_i \in T_{X_i}\mathcal{M}$ 과 결합하고, 지수사상으로 상태를 갱신한다 [Hairer et al., 2006]. 반면 식 (17)은 범주형 예측을 나타내는 점을 결합할 뿐이며 접벡터장을 평가하거나 평행이동하지 않는다. 따라서 계수의 일치는 국소적인 유사성일 뿐, 정확도 차수에 대한 증명이 아니다.

3.5 MDLM 및 SEDD에 대한 구체화

MDLM에서는 $\hat{z}_i$ 가 식 (7)의 p_{θ, t_i} 를 대체하며, 이미 마스크가 해제된 토큰은 고정된다. SEDD에서는 $\hat{z}_i$ 가 식 (8)의 정규화된 해석적 전이를 직접 대체한다. 두 경우 모두 다음 토큰 상태는 Gumbel-max로 추출하므로, 모든 신경망 입력은 이산 상태로 유지된다.

알고리즘 1 MDLM 또는 SEDD를 위한 측지 모멘텀 샘플링

입력: 사전학습 모델, 역방향 격자 $t_0 > \dots > t_N$, 모드 $\in \{\text{MDLM}, \text{SEDD}\}$

```
1:  $x \leftarrow$  전체 마스크 사전분포;  $\hat{u}_{-1} \leftarrow \emptyset$ 
2: 각각에 대해  $i = 0, \dots, N - 1$  반복
3:   만약 모드가 MDLM이면 이면
4:      $z_i \leftarrow p_{\theta, t_i}(\cdot | x)$ 
5:   아니면
6:     식 (8)으로  $\tilde{q}_i$  구성;  $z_i \leftarrow \text{Normalize}(\tilde{q}_i)$ 
7:    $u_i \leftarrow \sqrt{z_i}$ ; 식 (15)로  $\alpha_i$  계산
8:   만약  $i = 0$  이면
9:      $\hat{u}_i \leftarrow u_i$ 
10:  아니면
11:     $e_i \leftarrow \text{Slerp}(\hat{u}_{i-1}, u_i; 1 + \alpha_i)$ 
12:     $\hat{u}_i \leftarrow \text{Proj}_+(e_i)$ 
13:   $\hat{z}_i \leftarrow \hat{u}_i^{\odot 2}$ 
14:  만약 모드가 MDLM이면 이면
15:     $\hat{z}_i$ 를 식 (7)에 삽입; 마스크 위치를 샘플링하고 나머지는 복사
16:  아니면
17:     $x \sim \text{Cat}(\hat{z}_i)$ 
18: 기준 방법의 마지막 잡음 제거 단계를 적용하고  $x$  반환
```

4 이론적 적용 범위와 주장하지 않는 사항

본 방법은 다음의 정확한 성질을 보존한다.

1. **이산 상태 호환성.** 모델은 항상 정수 토큰 인덱스를 입력받는다.
2. **첫 스텝의 동치성.** $\alpha_0 = 0$ 이므로 같은 난수 추출을 사용할 때 첫 범주형 전이는 대응하는 기준 전이와 동일하다.
3. **단체 유효성.** 사영할 양의 부분이 0이 아니라는 조건 아래 모든 외삽 분포는 음이 아닌 값으로 정규화된다.
4. **MDLM 흡수 구조.** 이미 마스크가 해제된 토큰은 캐시를 사용하지 않는 MDLM 역방향 전이와 정확히 동일하게 고정된다.

그러나 샘플 시퀀스 x_{t_i} 는 확률적으로 변하므로 z_i 는 결정론적 주변분포 곡선 p_t 가 아니라 무작위 경로를 따라 얻은 조건부 예측들의 모음이다. SEDD에서 z_i 는 확률흐름 ODE의 상태가 아니라 한 스텝 전이 분포다. 또한 $p_k = 0$ 인 경계에서 Fisher-Rao 계량은 특이하지만, MDLM은 의도적으로 마스크 확률을 0으로 설정하고 이미 마스크가 해제된 토큰에는 델타 분포를 만든다. 제공된 표현은 이 경계에서도 수치적으로 사용할 수 있으나, 매끄러운 다양체에 기반한 Taylor 가정은 성립하지 않는다.

RDLM은 초구 위에 연속적인 브리지 혼합 SDE를 구성하고 연속 상태를 조건으로 하는 모델을 학습한다 [Jo and Hwang, 2025]. Fisher-Flow는 구면 측지선을 따라 확률질량을 운반하는 연속 벡터장을 학습한다 [Davis et al., 2024]. 본 방법은 이 두 작업을 수행하지 않는다. 마찬가지로 DPM-Solver는 확산 ODE의 정확한 준선형 적분 형태를 활용하여 고차 정확도를 얻지만 [Lu et al., 2022], 현재 이산 샘플러에는 그와 같은 구조가 없다. 따라서 본 연구는 주변분포 보존, 국소 절단오차 $O(h^3)$, 또는 전역 수렴 $O(h^2)$ 를 주장하지 않는다.

5 실험 결과의 평가

5.1 프로토콜

실험 스크립트는 MDLM을 자체 ddpm_cache 샘플러와 비교하고, SEDD를 자체 해석적 샘플러와 비교한다. 두 실험 모두 MDLM 코드베이스의 OpenWebText 체크포인트와 시퀀스 길이 1024를 사용한다. 역방향 스텝 수는 10, 20, 50, 100, 256, 512이다. 품질 지표는 다음과 같다.

- GPT-2로 계산한 토큰 가중 퍼플렉서티. 낮을수록 좋다.

표 1: 품질 결과. $\text{Gain}_{\text{PPL}} = 100(\text{baseline} - \text{geodesic})/\text{baseline}$ 이며, 양수이면 측지 모멘텀이 우세하다. 굵은 글씨는 각 쌍에서 더 낮은 값을 나타낸다.

모델	스텝	기준 PPL	측지 PPL	Gain_{PPL}	기준 JS	측지 JS
MDLM	10	551.953	407.473	+26.18%	0.38659	0.38850
	20	261.453	212.993	+18.53%	0.37718	0.38073
	50	140.075	120.542	+13.95%	0.36864	0.37629
	100	92.421	81.864	+11.42%	0.38260	0.38185
	256	65.431	65.665	-0.36%	0.37828	0.38066
	512	50.905	51.801	-1.76%	0.38224	0.37800
SEDD	10	486.276	434.932	+10.56%	0.35628	0.36043
	20	235.867	214.863	+8.91%	0.34810	0.34707
	50	123.169	114.949	+6.67%	0.34771	0.34503
	100	82.088	84.184	-2.55%	0.35678	0.35078
	256	59.954	63.276	-5.54%	0.34519	0.34670
	512	51.695	50.903	+1.53%	0.36408	0.36661

- 생성 텍스트와 참조 텍스트의 유니그램 토큰 히스토그램 사이의 Jensen-Shannon 발산. 낮을수록 좋다. 참조 문장은 WikiText-2 원시 검증 부분집합에서 가져온 비어 있지 않은 문자열이다.

5.2 품질 결과

MDLM의 10, 20, 50, 100 스텝에서 측지 샘플의 GPT-2 퍼플렉서티는 각각 26.18%, 18.53%, 13.95%, 11.42% 낮다. 256 및 512 스텝에서는 차이가 사라지고 기준 방법이 약간 우세하다. 이 패턴은 적은 스텝을 보정하려는 본 방법의 의도와 일치한다. 식 (16)의 MDLM 감쇠는 균일 격자의 스텝 수가 50을 넘으면 α 도 감소시킨다. 그 값은 100, 256, 512 스텝에서 각각 약 0.25, 0.098, 0.049다.

SEDD는 10-50 스텝에서 더 작은 퍼플렉서티 감소를 보이고, 100-256 스텝에서는 성능이 저하되며, 512 스텝에서는 작게 개선된다. 구현은 모든 균일 격자에서 첫 스텝 이후 $\alpha = 1/2$ 을 사용했고 MDLM의 고스텝 감쇠는 사용하지 않았다. 이것이 오버슈트에 기여했을 가능성은 있으나, 현재 실험만으로 원인을 분리할 수는 없다. Jensen-Shannon 발산은 두 모델 모두에서 결과가 혼재하며 일관된 분포 개선을 보이지 않는다.

6 논의

해석. 가장 방어 가능한 해석은 예측 지연 보정이다. 역방향 스텝이 적으면 연속된 잡음 제거 분포 또는 전이 분포가 크게 이동할 수 있다. 최근 Fisher-Rao 호를 연장하면 다음 예측을 앞서 추정하여 품질을 개선할 수 있다. 격자가 촘촘해질수록 원시 예측의 변화가 작아지므로 외삽의 이점은 줄어들고, 확률적 오차나 모델 오차를 증폭할 수 있다.

MDLM과 SEDD의 차이. MDLM은 흡수 전이 이전의 정답 토큰 예측에 모멘텀을 적용하고 완료된 토큰을 고정한다. SEDD는 확률적 상태에 의존하는 한 스텝 전이에 모멘텀을 적용한다. 후자의 대상은 시간에 따라 덜 매끄러울 수 있으며, 이는 곡선 외삽이라는 해석을 약화시키고 보존된 결과의 불안정한 경향과도 일치한다.

연속 기하 모델과의 관계. 본 방법은 Fisher-Flow 및 RDLM과 동일한 Fisher-Rao 매장을 사용하지만, 그 동역학을 사용하지는 않는다. 진정한 리만 다단계 솔버에는 연속 상태 X_t , 잘 정의된 접벡터장, $T_{X_{i-1}}\mathcal{M}$ 과 $T_{X_i}\mathcal{M}$ 사이의 평행이동, 그리고 지수사상에 의한 상태 갱신이 필요하다. 사전학습된 이산 MDLM 또는 SEDD를 위해 그러한 솔버를 확립하려면 범주형 예측과 연속 벡터장을 연결하는 새로운 유도가 필요하다.




그림 1: 퍼플렉시티 결과. 왼쪽 패널은 각 모델의 관측 범위에 맞춘 선형 세로축으로 원시 GPT-2 퍼플렉시티를 표시하므로 적은 스텝에서의 차이를 직접 확인할 수 있다. 오른쪽 패널은 상대 PPL 감소율 $(\text{baseline} - \text{geodesic}) / \text{baseline}$ 을 나타낸다. 양의 막대는 개선, 음의 막대는 저하를 뜻한다. 두 개선률 패널은 같은 $[-8, 30]$ 퍼센트포인트 범위를 유지한다.

7 한계

1. 수렴 차수를 보장하지 않음. 확률적 점프, 벡터가 아닌 점의 외삽, 재귀적 이력, 매끄럽지 않은 사영 때문에 AB2의 차수 논증을 직접 적용할 수 없다.
2. 경계 기하. 정확히 0인 성분은 Fisher-Rao 계량이 특이해지는 경계에 예측을 놓는다.
3. 위치별 근사. 각 토큰 위치를 서로 분리된 범주형 단체로 취급한다. 전체 결합 시퀀스 분포의 기하를 표현하지 않는다.

8 결론

본 논문은 Fisher-Rao 제곱근 구면 위에서 범주형 예측을 재귀적으로 외삽하는 MDLM 및 SEDD의 추론 시점 수정법인 측지 모멘텀 샘플링을 제시했다. 양의 직교영역 사영 이전의 갱신은 정확한 지수사상 해석을 가지며, 국소 계수는 가변 스텝 AB2 계수와 일치한다. 그러나 이 알고리즘은 확률흐름 ODE의 평행이동된 벡터장이 아니라 확률적 이산 경로에서 얻은 예측 점에 작용한다. 따라서 수학적으로 정확한 명칭은 증명된 2차 리만 솔버가 아니라 재귀적 Fisher-Rao 구면 외삽이다.

결과는 특히 MDLM의 적은 스텝에서 유망한 퍼플렉시티 경향을 보이지만, 분포 지표와 SEDD의 고스택

결과는 혼재한다. 형식적인 수렴성을 주장하려면 연속 벡터장에 기반한 유도가 필요하다.

참고문헌

- Shun-ichi Amari. *Information Geometry and Its Applications*. Springer, 2016. doi: 10.1007/978-4-431-55978-8.
- Oscar Davis, Samuel Kessler, Mircea Petrache, Ismail Ilkan Ceylan, Michael Bronstein, and Avishek Joey Bose. Fisher flow matching for generative modeling over discrete data. In *Advances in Neural Information Processing Systems*, 2024.
- Ernst Hairer, Christian Lubich, and Gerhard Wanner. *Geometric Numerical Integration: Structure-Preserving Algorithms for Ordinary Differential Equations*. Springer, 2 edition, 2006. doi: 10.1007/3-540-30666-8.
- Jaehyeong Jo and Sung Ju Hwang. Continuous diffusion model for language modeling. In *Advances in Neural Information Processing Systems*, 2025.
- Aaron Lou, Chenlin Meng, and Stefano Ermon. Discrete diffusion modeling by estimating the ratios of the data distribution. In *Proceedings of the 41st International Conference on Machine Learning*, volume 235 of *Proceedings of Machine Learning Research*, 2024.
- Cheng Lu, Yuhao Zhou, Fan Bao, Jianfei Chen, Chongxuan Li, and Jun Zhu. DPM-Solver: A fast ODE solver for diffusion probabilistic model sampling in around 10 steps. In *Advances in Neural Information Processing Systems*, 2022.
- Subham Sekhar Sahoo, Marianne Arriola, Yair Schiff, Aaron Gokaslan, Edgar Marroquin, Justin T. Chiu, Alexander Rush, and Volodymyr Kuleshov. Simple and effective masked diffusion language models. In *Advances in Neural Information Processing Systems*, 2024.
- Ken Shoemake. Animating rotation with quaternion curves. *ACM SIGGRAPH Computer Graphics*, 19(3): 245–254, 1985. doi: 10.1145/325165.325242.